

Санкт-Петербургский политехнический университет Петра Великого

Физико Механический институт

**Высшая школа прикладной математики и вычислительной физики**

**Отчёт по лабораторной работе №3**

по дисциплине

«Математическая статистика»

Выполнила студент

группы 5030102/90101

Кузин Иван Никитович

Проверил

Доцент, к.ф.-м.н.

Баженов Александр Николаевич

Санкт-Петербург

2022

# Содержание

<b>Список иллюстраций</b>	3
<b>1 Постановка задачи</b>	4
<b>2 Теория</b>	4
2.1 Боксплот Тьюки	4
2.1.1 Определение	4
2.1.2 Описание	4
2.1.3 Построение	4
2.2 Теоретическая вероятность выбросов	5
<b>3 Программная реализация</b>	5
<b>4 Результаты</b>	6
4.1 Боксплот Тьюки	6
4.2 Доля выбросов	8
4.3 Теоретическая вероятность выбросов	9
<b>5 Обсуждение</b>	9
<b>6 Приложение</b>	9

## Список иллюстраций

1	Нормальное распределение . . . . .	6
2	распределение Коши . . . . .	6
3	распределение Лапласа . . . . .	7
4	распределение Пуассона . . . . .	7
5	равномерное распределение . . . . .	8

# 1 Постановка задачи

Для 5 распределений:

1.  $N(x, 0, 1)$  – нормальное распределение
2.  $C(x, 0, 1)$  – распределение Коши
3.  $L(x, 0, \frac{1}{\sqrt{2}})$  – распределение Лапласа
4.  $P(k, 10)$  – распределение Пуассона
5.  $U(x, -\sqrt{3}, \sqrt{3})$  – расномерное распределение

Сгенерировать выборки размером 20 и 100 элементов. Построить для них боксплот Тьюки. Для каждого распределения определить долю выбросов экспериментально (сгенерировав выборку, соответствующую распределению 1000 раз, и вычислив среднюю долю выбросов) и сравнить с результатами, полученными теоретически.

# 2 Теория

## 2.1 Боксплот Тьюки

### 2.1.1 Определение

Боксплот (англ. box plot) — график, использующийся в описательной статистике, компактно изображающий одномерное распределение вероятностей

### 2.1.2 Описание

Такой вид диаграммы в удобной форме показывает медиану, нижний и верхний квартили и выбросы. Несколько таких ящиков можно нарисовать бок о бок, чтобы визуально сравнивать одно распределение с другим; их можно располагать как горизонтально, так и вертикально. Расстояния между различными частями ящика позволяют определить степень разброса (дисперсии) и асимметрии данных и выявить выбросы.

### 2.1.3 Построение

Границами ящика служат первый и третий квартили, линия в середине ящика — медиана. Концы усов — края статистически значимой выборки (без выбросов). Длину «усов» определяют разность первого квартиля и полутора межквартильных расстояний и сумма третьего квартиля и полутора межквартильных расстояний. Формула имеет вид

$$X_1 = Q_1 - \frac{3}{2}(Q_3 - Q_1), X_2 = Q_3 + \frac{3}{2}(Q_3 - Q_1) \quad (1)$$

где  $X_1$  — нижняя граница уса,  $X_2$  — верхняя граница уса,  $Q_1$  — первый квартиль,  $Q_3$  — третий квартиль. Данные, выходящие за границы усов (выбросы), отображаются на графике в виде маленьких кружков.

## 2.2 Теоретическая вероятность выбросов

Встроеннымми средствами языка программирования Python в среде разработки PyCharm можно вычислить теоретические первый и третий квартили распределений ( $Q_1^T$  и  $Q_3^T$  соответственно). По формуле (1) можно вычислить теоретические нижнюю и верхнюю границы уса ( $X_1^T$  и  $X_2^T$  соответственно). Выбросами считаются величины  $x$ , такие что:

$$\begin{cases} x < X_1^T \\ x > X_2^T \end{cases} \quad (2)$$

Теоретическая вероятность выбросов для непрерывных распределений

$$P_B^T = P(x < X_1^T) + P(x > X_2^T) = F(X_1^T) + (1 - F(X_2^T)) \quad (3)$$

где  $F(X) = P(x \leq X)$  - функция распределения. Теоретическая вероятность выбросов для дискретных распределений

$$P_B^T = P(x < X_1^T) + P(x > X_2^T) = (F(X_1^T) - P(x = X_1^T)) + (1 - F(X_2^T)) \quad (4)$$

где  $F(X) = P(x \leq X)$  - функция распределения

## 3 Программная реализация

Лабораторная работа выполнена на языке Python вредии 3.7 в среде разработки JupyterLab. Использовались дополнительные библиотеки:

1. scipy - статистические распределения и функции
2. seaborn - построение графиков, визуализация
3. matplotlib - построение графиков
4. math - использование математических функций

В приложении находится ссылка на GitHub репозиторий с исходными кодом.

## 4 Результаты

### 4.1 Боксплот Тьюки




Рис. 1: Нормальное распределение




Рис. 2: распределение Коши




Рис. 3: распределение Лапласа




Рис. 4: распределение Пуассона




Рис. 5: равномерное распределение

## 4.2 Доля выбросов

Округление доли выбросов:

Выборка случайна, поэтому в качестве оценки рассеяния можно взять дисперсию пуассоновского потока:  $D_n \approx \sqrt{n}$

$$\text{Доля } p_n = \frac{D_n}{n} = \frac{1}{\sqrt{n}}$$

Доля  $n = 20$  :  $p_n = \frac{1}{\sqrt{20}}$  - примерно 0.2 или 20%

Для  $n = 100$  :  $p_n = \frac{1}{\sqrt{100}}$  - примерно 0.1 или 10%

Исходя из этого можно решить, сколько знаков оставлять в доле выброса.

Выборка	Доля выбросов	$P_B^T$
Normal n=20	0.024	0.007
Normal n=100	0.014	0.007
Cauchy n=20	0.151	0.156
Cauchy n=100	0.185	0.156
Laplace n=20	0.075	0.063
Laplace n=100	0.081	0.063
Poisson n=20	0.024	0.008
Poisson n=100	0.016	0.008
Uniform n=20	0.002	0
Uniform n=100	0	0

Таблица 1: Доля выбросов

### 4.3 Теоретическая вероятность выбросов

Распределение	$Q_1^T$	$Q_3^T$	$X_1^T$	$X_2^T$	$P_B^T$
Нормальное распределение	-0.674	0.674	-2.698	2.698	0.007
Распределение Коши	-1	1	-4	4	0.156
Распределение Лапласа	-0.490	0.490	-1.961	1.961	0.063
Распределение Пуассона	8	12	2	18	0.008
Равномерное распределение	-0.866	0.866	-3.464	3.464	0

Таблица 2: Теоретическая вероятность выбросов

## 5 Обсуждение

По данным, приведенным в таблице, можно сказать, что чем больше выборка (в нашем случае для 100 элементов), тем ближе доля выбросов будет к теоретической оценке. Снова доля выбросов для распределения Коши значительно выше, чем для остальных распределений. Для распределений: нормального, Лапласа и Пуассона погрешность при большой выборке составила не более 2 процентов. При увеличении выборки равномерное распределение показывает стремительный рост к теоретической оценке - выбросы практически не наблюдаются.

Ящики с «усами» в удобной форме показывает многие важные характеристики выборки, такие как медиана, первый и третий квартили и другие. Исходя из которых можно делать выводы касательно природы входных данных, распределений.

## 6 Приложение

Код программы GitHub URL:

<https://github.com/workivan/mat-ver-stat.git>